

// INFERENCE • UNBUNDLED

WEAVER.

Efficiently distributed and parallelized.

Scalable GPU-based inference. Deployable on any cloud. Deploy without any code or config.

// THE DEMAND

La inferencia explotó. Y no frena.

330×

Google: 9.7T → 3.2 quadrillion tokens/mes en
25 meses
(Pichai, I/O 2024→2026)

6B+

tokens por minuto en la API de OpenAI · 800M
usuarios/semana
(Altman, DevDay oct-2025)

100T+ /yr

OpenRouter — 10× en un año; 25T/mes, 5M
usuarios
(a16z State of AI, dic-2025)

fuentes: blog.google I/O 2026 · [techcrunch](https://techcrunch.com) DevDay 2025 · a16z.com/state-of-ai · openrouter.ai

// THE BOTTLENECK

El cómputo centralizado no alcanza — y cuesta una fortuna.

\$646B

capex hyperscalers 2026 — ~2% del PIB de
USA
(Apollo, feb-2026)

3-7 años

de espera para conectar un datacenter al grid
en USA
(LBNL · Dominion)

63%

del cloud en 3 proveedores: AWS 30 · Azure 20 ·
GCP 13
(Synergy, Q2-2025)

Y en el medio, **un peaje** sobre cada token.

OpenRouter

0% markup por token — pero cobra por **cargar** créditos. Disponibilidad "as-available": sin garantía.

5.5%-8% fee

Fireworks

Serverless admite por escrito cero garantías de latencia. Su 99.9% solo cubre el 503 genuino.

0 SLA

Together

La garantía (99% + throughput) se compra aparte: PTU contratado. Serverless = best-effort.

\$0.05/PTU·min

Replicate

En despliegues privados factura setup + idle + activo. Pagás la espera del centralizado.

H100 \$5.49/h

OpenCode Go

\$10/mes por hasta \$60 de modelos abiertos, caps de \$15 por modelo. Suscripción que racionaliza lo abierto.

cap \$15/modelo

// THE SUPPLY

La mayoría del silicio del planeta ya está instalada — en las casas.

~75%

de los FLOPS brutos del planeta viven en
dispositivos de usuario — no en datacenters
(base instalada: Gartner/IDC/Uptime)

30-50x

dispositivos de usuario por cada servidor
físico (~6.000M edge vs ~40M servers)

2.4 EFLOPS

Folding@home en 2020 — más que las 500
supercomputadoras del TOP500 juntas, con
PCs donadas

fuentes: base instalada IDC/Gartner · servers Uptime/Synergy · Folding@home mar-2020 · utilización edge ~5-15% diaria

// THE CATCH

El matiz: no entrenás GPT-6 sobre WiFi.

Pero no hace falta.

1000x

penalización de latencia: residencial ~ms vs InfiniBand ~μs — destruye el paralelismo de entrenamiento


1

request = una isla. La inferencia es embarrassingly parallel: cero coordinación entre nodos — el patrón donde el edge ya ganó (F@H, BOINC)

El edge no entrena la frontera — **la sirve**. No falta cómputo: falta el mercado — routing, verificación y pagos que hagan confiable a una red de desconocidos.

Un mercado de inferencia donde **cualquiera** sirve y cobra.

El gateway rutea por TTFT y tok/s **medidos** — no declarados. Los forges aportan GPUs por WebSocket autenticado. Stellar liquida cada job en escrow verificable.



Confianza sin confiar.

01 / MEASURED

Routing por medida, no por marketing

Cada instancia reporta carga y estado HOT/COLD; el gateway mide `TTFT p50` y `tok/s` reales por request y rankea por ETR. Warm-first, failover explícito, métricas nulas jamás inventadas.

02 / VERIFIED

Proof de entrega por job

Attestation por benchmark determinístico al conectar. Cada resultado lleva `hash sha256` firmado con la clave `ed25519` del forge. Audit replay con referencia cross-operator; strikes persistentes.

03 / PAID

Escrow on-chain, self-claim

Contrato Soroban: `fund_job` ata el pago al worker, `release` exige el proof — sin firma válida no hay pago. Ventana de 24h anti-refund-rug: el forge cobra aunque el operador desaparezca.

// THE PRODUCT

Tu key. Tu billing. Funciona donde ya trabajás.

```
# opencode.json - una línea y estás dentro
"provider": {
  "weaver": {
    "npm": "@ai-sdk/openai-compatible",
    "options": { "baseUrl": "https://gw.weaver/v1",
                  "apiKey": "wvr_..." }
  }
}

# mismo Bearer en pi · hermes · cursor · curl
# billing: USDC prepago, debit por tokens MEDIDOS
```

/account - panel self-serve

/models - marketplace live

402 si no hay crédito

SSE streaming real

No es un slide. Está corriendo.

262+

tests verdes entre packages, gateway, web y contrato

v5

contrato escrow: self-claim + ventana anti-rug + upgrade

WS

forges remotos: attestation, heartbeats, rate-limit, failover

e2e

smoke live: cuenta → depósito USDC → stream → debit → settle

/v1

OpenAI-compatible: chat, images, catalog, usage, keys

testnet

pagos reales verificables en stellar.expert

0

prompts guardados — viven en RAM y mueren con el request

1

repo · pnpm monorepo · TS + Rust · ADRs documentados

// AND NOW

Todo lo que viste **corre.**

- ▶ job real → forge remoto → stream de tokens
- ▶ TTFT medido en vivo, failover si el nodo cae
- ▶ escrow: fund → proof → release en stellar.expert
- ▶ debit medido en /v1/me · marketplace actualizando

LIVE DEMO →